PROCESAMIENTO DEL LENGUAJE NATURAL

Práctica 1: Preparación y procesamiento de textos

Universidad Autónoma de Madrid

Iván Domínguez Hernández | ivan.dominguezh@estudiante.uam.es

Lucas Miranda López | lucas.mirandal@estudiante.uam.es

Índice

1. Descarga y preparación de la información **2**

2. Diseñar e implementar el gestor del corpus **2**

3. Preprocesamiento del corpus y análisis básicos **2**

1. Descarga y preparación de la información

Resumen: En esta primera sección se descarga de uno los ficheros del corpus de comentarios de *Amazon* (uno sencillo y poco pesado, el de tarjetas de regalo) y se diseña la clase *ProcesadorDeTexto* para almacenar cada review en un fichero propio en el directorio que le corresponda sin almacenar reviews duplciadas.

1. La decisión de descargar el fichero *Gift_ Cards.jsonl* se debe únicamente a su tamaño. Teniendo en cuenta que todos ficheros del corpus de *Amazon* siguen la misma estructura JSON, lo óptimo para la realización de la práctica parecía ser escoger un fichero ligero sobre el que hacer pruebas en un archivo dde tipo *.ipynb* para, posteriormente, codificar sencillamente el archivo *.py* definitvo y genérico capaz de procesar cualquier fichero del corpus.

2. Las pruebas realizadas sobre el archivo *.ipynb* auxiliar permitieron construir la clase *ProcesadorDeTexto*, capaz de:

   a) Recibir el nombre del fichero a preprocesar (sin especificar su extensión, solo el nombre del fichero). En nuestro caso 'Gift_Cards'.

   b) Recibir una lista con las categorías que el usuario quiera almacenar para cada reseña. Nosotros aconsejamos pasarle la lista ['rating', 'title', 'text', 'parent_asin', 'user_id'], que almacena la puntación en estrellas del 1 al 5, el título (tal vez contenga información relevante), el texto per se de la reseña, una referencia al tipo de producto reseñado (que posteriormente permitirá acceder a metainformación de ser preciso) y una referencia al usuario que hace la reseña.

   Y ahora, iterando sobre cada elemento del *.jsonl* a procesar:

   c) No almacenar reseñas que, siendo del mismo usuario y al mismo producto, tienen el mismo texto y título. Se puede pensar que esto debería ser parte de un posterior preprocesado. Pero al implicar iterar sobre cada elemento de nuevo, decidimos hacerlo en este paso para ahorrar cómputo a posteriori.

   d) Guardar las categorías enunciadas en la lista que se le pase de cada reseña en un fichero propio, en tres distintos directorios. */positivas, /neutras* y */negativas*, a modo de etiqueta, basándonos únicamente a cual de los intervalos pertenece la categoría *'rating'*: $rating \geq 4.5$, $4.5 \geq rating \geq 1.5$ o $rating \leq 1.5$. Es un criterio absurdo, pero al ser configurable, de momento no nos preocuparemos por esto en esta práctica.

Por tanto, lo que podemos obtener tras esta sección es una división en directorios, basada en la puntuación de cada reseña, en los que se incluyen ficheros *.json*, para cada reseña, y que contienen las categorías especificadas por el usuario. Esto facilitará en gran medida la posterior ingesta (2) de datos por un gestor de corpus especializado en nuestro caso, *AmazonCorpusReader*. **Nota:** los directorios que se crean están bastante desbalanceados. Esto es, existen muchas más reseñas de clase positiva que de clases neutra o negativa. Esto es, en realidad, una distribución inherente, no solo al criterio seguido para el etiquetado, sino también a los propios datos. Y es que lo normal es que los usuarios hagan tantas reseñas negativas o neutras como positivas.

2. Diseñar e implementar el gestor del corpus

A rellenar por Lucas.

3. Preprocesamiento del corpus y análisis básicos